

Universidad Veracruzana
Facultad de Estadística e Informática

Proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD)

Aplicación de un Árbol de Decisión para la predicción de depresión en estudiantes

Maestra: Lorena López Lozada

Alumnos: Cristian Axel Izquierdo Lopez¹, Laura Yoselin Tonil De La Luz²

Experiencia Educativa: Metodología de la Investigación

Xalapa de Enríquez, Veracruz

14 de septiembre de 2026

Introducción

El descubrimiento de conocimiento en bases de datos, conocido como proceso KDD (Knowledge Discovery in Databases), es una metodología sistemática que permite transformar grandes volúmenes de datos en bruto en conocimiento útil, válido y comprensible. Como se ilustra en el esquema de referencia utilizado para este trabajo, el proceso se compone de siete etapas secuenciales: (1) selección de datos, (2) recolección/integración, (3) limpieza de datos, (4) transformación de datos, (5) minería de datos, (6) evaluación de patrones y (7) presentación del conocimiento.

En este reporte se aplica el proceso KDD completo sobre el conjunto de datos Student Depression Dataset, el cual contiene información sociodemográfica, académica y de estilo de vida de 27,901 estudiantes, con el objetivo de construir un modelo de minería de datos —un árbol de decisión— capaz de predecir la presencia de depresión (variable depression) a partir de dichas características. Cada una de las secciones siguientes documenta una etapa del proceso, describiendo las decisiones metodológicas tomadas, el código empleado y los resultados obtenidos.

1. Selección de los datos

En esta primera etapa del proceso KDD se identifica la fuente de datos y se determinan las variables que serán utilizadas en el análisis. El conjunto de datos original, Student_Depression_Dataset.csv, fue recolectado como una única fuente tabular (etapa de recolección/integración) y contiene 27,901 registros y 18 columnas.

```
import pandas as pd
datos = pd.read_csv('Student_Depression_Dataset.csv')
print(datos.shape)  # (27901, 18)
```

Las variables originales incluyen datos demográficos (Gender, Age, City), académicos y laborales (Profession, Academic Pressure, Work Pressure, CGPA, Study Satisfaction, Job Satisfaction, Degree), de estilo de vida (Sleep Duration, Dietary Habits, Work/Study Hours), psicosociales (Have you ever had suicidal thoughts?, Financial Stress, Family History of Mental Illness) y la variable identificadora id. La variable objetivo es Depression (1 = presencia de depresión, 0 = ausencia).

Se eliminaron del conjunto de variables predictoras la columna id, por tratarse únicamente de un identificador sin valor predictivo, así como las columnas City, Profession y Degree, debido a su elevada cardinalidad (52, 14 y 28 categorías distintas respectivamente), lo cual dificultaría tanto la interpretación del árbol de decisión como su capacidad de generalización si se codificaran de manera simple.

```
cols_drop = ['id', 'City', 'Profession', 'Degree']
datos = datos.drop(columns=cols_drop)
print(datos.shape)  # (27901, 14)
```

Tras esta selección, el conjunto de datos quedó conformado por 14 variables (13 predictoras más la variable objetivo), conservando la información más relevante desde el punto de vista sustantivo para explicar la depresión en estudiantes.

2. Limpieza de datos

En la etapa de limpieza se revisó la calidad del conjunto de datos, identificando valores faltantes y registros duplicados que pudieran afectar el entrenamiento del modelo.

```
print(datos.isnull().sum())
print('Duplicados:', datos.duplicated().sum())
```

La revisión mostró 2 registros duplicados y valores faltantes únicamente en la variable Financial Stress (Financial Stress: 3 valores). Ambos problemas se resolvieron eliminando los registros duplicados y aquellos con datos incompletos, dado que representan una proporción mínima del total (menos del 0.02% de las observaciones) y su eliminación no compromete la representatividad del conjunto de datos.

```
datos = datos.dropna().copy()
datos = datos.drop_duplicates().copy()
```

Dimensiones después de la limpieza: (27,896, 14).

Revisión de la variable objetivo

Se examinó la distribución de la variable Depression para verificar que se trata de una variable binaria y conocer el balance de clases, aspecto relevante para la posterior evaluación del modelo.

Depression	Frecuencia	Proporción
1 (con depresión)	16,334	58.55 %
0 (sin depresión)	11,562	41.45 %

La distribución muestra un ligero desbalance hacia la clase positiva (58.6% de los estudiantes presentan depresión frente a 41.5% que no la presentan), lo cual es razonablemente equilibrado y no requiere técnicas de rebalanceo adicionales para este análisis.

3. Transformación de los datos

En esta etapa se separaron las variables predictoras (X) de la variable objetivo (y), y se codificaron las variables categóricas a valores numéricos mediante LabelEncoder, de forma análoga al procedimiento empleado en el análisis de referencia.

```
X = datos.drop(columns=['Depression'])
y = datos['Depression']
```

```
from sklearn.preprocessing import LabelEncoder
for columna in X.select_dtypes(include=['object']).columns:
    le = LabelEncoder()
    X[columna] = le.fit_transform(X[columna].astype(str))
```

Las variables categóricas codificadas fueron: Gender, Sleep Duration, Dietary Habits, Have you ever had suicidal thoughts ?, Family History of Mental Illness. El resto de las variables (Age, Academic Pressure, Work Pressure, CGPA, Study Satisfaction, Job Satisfaction, Work/Study Hours, Financial Stress) ya se encontraban en formato numérico.

Al igual que en el análisis de referencia, no fue necesario aplicar escalamiento o estandarización a las variables, dado que los árboles de decisión son invariantes a la escala de los predictores.

División de los datos

El conjunto de datos se dividió en un subconjunto de entrenamiento (80%) y uno de prueba (20%), utilizando muestreo estratificado sobre la variable objetivo para conservar la proporción de clases en ambos subconjuntos.

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=123, stratify=y
)
```

Subconjunto	Registros	Variables
Entrenamiento	22,316	13
Prueba	5,580	13

4. Minería de datos: árbol de decisión

Se entrenó un modelo de árbol de decisión (DecisionTreeClassifier de scikit-learn) utilizando el criterio de impureza Gini y una profundidad máxima de 4 niveles, con el fin de mantener un modelo interpretable sin sacrificar de forma importante su capacidad predictiva.

```
from sklearn.tree import DecisionTreeClassifier
arbol = DecisionTreeClassifier(criterion='gini', max_depth=4, random_state=123)
arbol.fit(X_train, y_train)
```

Visualización del árbol

La figura 1 muestra la estructura completa del árbol entrenado. La primera división del árbol se realiza sobre la variable Have you ever had suicidal thoughts?, lo que indica que es el predictor más determinante para separar a los estudiantes con y sin depresión, seguida de Academic Pressure y Financial Stress en los niveles subsecuentes.




Figura 1. Árbol de decisión entrenado para la predicción de depresión en estudiantes (profundidad máxima = 4).

5. Evaluación de patrones

Una vez entrenado el modelo, se generaron predicciones sobre el conjunto de prueba y se evaluó su desempeño mediante las métricas estándar de clasificación: exactitud (accuracy), precisión, sensibilidad (recall) y F1-score.

```
y_pred = arbol.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred, average='weighted')
recall = recall_score(y_test, y_pred, average='weighted')
f1 = f1_score(y_test, y_pred, average='weighted')
```

Métrica	Valor
Accuracy	0.8246
Precision	0.8252
Recall	0.8246
F1-score	0.8223

El modelo alcanzó una exactitud de 82.5% sobre el conjunto de prueba, lo que indica un desempeño satisfactorio para un modelo de estructura relativamente simple (profundidad máxima de 4 niveles). Las métricas de precisión, recall y F1-score, muy cercanas entre sí, sugieren un comportamiento equilibrado del modelo entre ambas clases.

Matriz de confusión

De los 5580 estudiantes del conjunto de prueba, el modelo clasificó correctamente a 1671 estudiantes sin depresión y 2930 estudiantes con depresión. Se registraron 642 falsos positivos (estudiantes sin

depresión clasificados incorrectamente como con depresión) y 337 falsos negativos (estudiantes con depresión no detectados por el modelo).




Figura 2. Matriz de confusión del árbol de decisión sobre el conjunto de prueba.

Importancia de las variables

El análisis de importancia de variables —calculado a partir de la reducción de impureza Gini que aporta cada predictor— permite identificar qué factores resultan más relevantes para el modelo al momento de discriminar entre estudiantes con y sin depresión.

Variable	Importancia
Have you ever had suicidal thoughts ?	0.6253
Academic Pressure	0.2507
Financial Stress	0.1020
Dietary Habits	0.0143
Age	0.0077




Figura 3. Importancia relativa de las variables en el árbol de decisión.

Los resultados muestran que la variable con mayor peso predictivo es Have you ever had suicidal thoughts? (62.5% de la importancia total), seguida de Academic Pressure (25.1%) y Financial Stress (10.2%). En conjunto, estas tres variables explican más del 97% de las decisiones tomadas por el árbol, mientras que variables como CGPA, Work Pressure, Gender, Study Satisfaction, Sleep Duration, Job Satisfaction, Work/Study Hours y Family History of Mental Illness no fueron utilizadas por el modelo dentro de la profundidad máxima establecida.

6. Presentación del conocimiento

La etapa final del proceso KDD consiste en comunicar el conocimiento descubierto de forma clara, útil y válida para la toma de decisiones. A partir del análisis realizado se pueden establecer las siguientes conclusiones:

- El factor más determinante en la presencia de depresión entre los estudiantes analizados es haber tenido pensamientos suicidas alguna vez, lo cual concuerda con la literatura clínica que identifica a la ideación suicida como un indicador central de trastornos depresivos.
- La presión académica es el segundo factor más importante, lo que sugiere que las exigencias escolares (carga de trabajo, exámenes, expectativas de rendimiento) inciden de forma relevante en la salud mental de los estudiantes.
- El estrés financiero aporta una contribución adicional y no despreciable, lo que apunta a que las dificultades económicas también son un factor de riesgo asociado.
- El modelo, a pesar de su estructura sencilla (profundidad máxima de 4 niveles), alcanza una exactitud de 82.5%, lo que lo convierte en una herramienta interpretable y razonablemente confiable para apoyar la identificación temprana de estudiantes en riesgo.

- Variables como el género, la duración del sueño, la satisfacción laboral/académica y los antecedentes familiares no resultaron determinantes para este modelo particular, lo cual no significa que carezcan de relación con la depresión, sino que su efecto queda subsumido por variables más fuertes como la ideación suicida y la presión académica.

Estos hallazgos, resumidos en la tabla y las figuras anteriores, constituyen el conocimiento útil, válido y comprensible que resulta de aplicar el proceso KDD sobre el conjunto de datos analizado, y pueden emplearse como insumo para el diseño de estrategias de detección y apoyo psicológico dirigidas a estudiantes.

Conclusión general

La aplicación completa del proceso KDD —selección, limpieza, transformación, minería de datos y evaluación de patrones— sobre el conjunto de datos Student Depression Dataset permitió construir un árbol de decisión capaz de predecir la presencia de depresión en estudiantes con un desempeño satisfactorio ($\text{accuracy} = 0.8246$, $F1 = 0.8223$). El seguimiento riguroso de cada etapa metodológica garantizó que los datos utilizados para el entrenamiento fueran de calidad (sin duplicados ni valores faltantes) y que las variables empleadas tuvieran sentido sustantivo para el problema estudiado. El modelo resultante, además de su valor predictivo, ofrece una interpretación clara de los factores más asociados a la depresión estudiantil, cumpliendo así con el objetivo final del proceso KDD: transformar datos en bruto en conocimiento útil, válido y comprensible para la toma de decisiones.